

Proiect analiza datelor(Global Terrorism)
Universitatea tehnica Cluj Napoca-filiala Baia Mare

Danciu Cătălin

Mai 2025

Contents

1	Introducere	2
1.1	Descrierea	2
1.2	Motivația alegerii temei	2
1.3	Scopul proiectului	2
2	Contextul sursei de date și al proiectului	2
2.1	Descrierea sursei de date	2
2.2	Problema abordată	3
2.3	Obiectivele proiectului	3
3	Aspecte teoretice relevante	4
3.1	Învățarea automată în probleme de clasificare	4
3.2	Modele utilizate	4
3.3	Prelucrarea și selecția datelor	4
3.4	Starea actuală a cercetării	4
3.5	Concluzii teoretice	5
4	Implementarea aspectelor teoretice	5
4.1	Preprocesarea datelor	5
4.2	Modelarea datelor	5
5	Testare si validare	6
6	Rezultate	6
6.1	Rezultate obținute	6
6.2	Compararea cu soluții existente	6
7	Concluzii și perspective de viitor	6
7.1	Concluzii	6
7.2	Perspective de viitor	6

1 Introducere

1.1 Descrierea

Analiza datelor a devenit un domeniu de interes major în ultimii ani, remarcându-se prin eficiența sa și prin gama largă de aplicații. Aceasta joacă un rol esențial în extragerea și anticiparea unor informații relevante pentru utilizatori.

Analiza fenomenelor teroriste reprezintă o provocare semnificativă atât din punct de vedere geopolitic, cât și din perspectiva securității naționale. Înțelegerea tiparelor din spatele acestor evenimente poate contribui la prevenirea și gestionarea lor mai eficientă.

Pentru acest proiect, am utilizat setul de date **Global Terrorism Database**. Acest set conține informații despre peste 180.000 de incidente teroriste petrecute în întreaga lume începând cu anul 1970 până în prezent.

1.2 Motivația alegerii temei

Motivația alegerii acestei baze de date constă în:

- volum mare de date etichetate, esențial pentru antrenarea unor modele de învățare automată;
- acoperire globală și temporală extinsă, ceea ce permite detectarea unor tipare recurente;
- caracterul public și bine documentat al bazei de date.

1.3 Scopul proiectului

Scopul proiectului este de a aplica metode predictive pentru a analiza factorii relevanți care pot influența succesul unui atac terorist. Mai precis, se urmărește estimarea probabilității ca un atac să fie considerat reușit pe baza caracteristicilor cunoscute ale incidentului. Alegerea bazei Global Terrorism susține acest demers prin structura sa detaliată și prin disponibilitatea unor variabile esențiale pentru construirea unor modele de clasificare eficiente.

2 Contextul sursei de date și al proiectului

2.1 Descrierea sursei de date

Setul de date utilizat în acest proiect este **Global Terrorism Database (GTD)**, disponibil public prin intermediul organizației *START*. Acesta reprezintă una dintre cele mai complete surse de date despre terorismul la nivel global, incluzând peste 180.000 de incidente înregistrate începând cu anul 1970. Fiecare înregistrare conține informații detaliate despre:

- data și locația atacului;

- tipul de atac (bombardament, atac armat, etc.);
- gruparea responsabilă (dacă este cunoscută);
- ținta atacului;
- armele utilizate;
- numărul de victime (morți și răniți);
- succesul sau eșecul atacului;
- alte variabile contextuale.

Fișierul original în format CSV a fost prelucrat pentru a elimina coloanele redundante, valorile lipsă și datele irelevante pentru scopul analizei.

2.2 Problema abordată

În cadrul acestui proiect, ne propunem să rezolvăm o problemă de clasificare binară: determinarea probabilității ca un atac terorist să fie considerat **reușit**, în funcție de atributele disponibile la momentul incidentului. Se consideră că un atac este reușit dacă a avut impactul planificat (conform valorii atributului `success = 1` din setul de date).

Această sarcină implică prelucrarea datelor, selectarea caracteristicilor relevante, antrenarea și evaluarea unor modele de clasificare pe baza performanței acestora.

2.3 Obiectivele proiectului

Obiectivele principale ale proiectului sunt:

- analizarea și curățarea setului de date pentru a obține un subset relevant;
- explorarea distribuției și corelațiilor dintre variabile;
- aplicarea și compararea mai multor modele de clasificare, precum *Random Forest*, *Logistic Regression* și *XGBoost*;
- evaluarea performanței modelelor utilizând metrici standard (precizie, acuratețe, AUC etc.);
- identificarea celor mai influente caracteristici asupra probabilității de succes a unui atac.

Prin acest demers, se urmărește dezvoltarea unui model capabil să ofere interpretări utile asupra factorilor care contribuie la succesul atacurilor, cu scopul final de a îmbunătăți capacitatea de analiză a riscurilor în domeniul securității.

3 Aspecte teoretice relevante

3.1 Învățarea automată în probleme de clasificare

Machine Learning este o ramură a inteligenței artificiale care permite sistemelor informatice să învețe din date și să ia decizii fără a fi explicit programate. În cadrul acestui proiect, ne concentrăm asupra **învățării supervizate**, în special asupra problemelor de **clasificare binară**, unde scopul este de a încadra un exemplu într-una dintre cele două clase posibile: atac reușit (**success** = 1) sau nereușit (**success** = 0).

3.2 Modele utilizate

Logistic Regression Logistic Regression este un model liniar folosit frecvent pentru clasificarea binară. Aceasta estimează probabilitatea ca un eveniment să apară.

Random Forest Random Forest este un algoritm de tip ansamblu (ensemble) care construiește mai mulți arbori de decizie și agregă predicțiile acestora. Este rezistent la overfitting și eficient în clasificări complexe. A fost introdus de Breiman (2001)

XGBoost XGBoost (Extreme Gradient Boosting) este un algoritm de boosting performant, cunoscut pentru acuratețea sa. Se bazează pe adăugarea iterativă de arbori de decizie care corectează erorile modelelor anterioare

3.3 Prelucrarea și selecția datelor

Datele brute conțin frecvent erori, valori lipsă și informații irelevante. Curățarea presupune:

- eliminarea valorilor lipsă și a duplicatelor;
- conversia variabilelor categorice în formă numerică;
- normalizarea datelor;
- selecția caracteristicilor relevante folosind metode statistice sau scoruri de importanță.

3.4 Starea actuală a cercetării

Mai multe lucrări au aplicat metode de învățare automată pentru analiza incidentelor teroriste. Printre acestea:

3.5 Concluzii teoretice

Dintre modelele analizate, **Random Forest** a demonstrat cel mai bun echilibru între precizie și recall, obținând cel mai ridicat **F1-score** în cadrul testelor realizate. Acest scor este deosebit de relevant în probleme dezechilibrate, cum este cazul clasificării succesului unui atac terorist, unde distribuția claselor poate fi inegală.

Prin urmare, modelul Random Forest a fost selectat pentru implementarea finală datorită:

- capacității sale de a gestiona un număr mare de variabile și relații non-liniare;
- interpretabilității moderate (prin analiza importanței caracteristicilor);
- performanței superioare în ceea ce privește scorul F1, comparativ cu modelele Logistic Regression și XGBoost.

4 Implementarea aspectelor teoretice

4.1 Preprocesarea datelor

Pentru început, fișierul original `globalterrorism.csv` a fost încărcat în cadrul unui notebook Jupyter utilizând biblioteca `pandas`. Au fost aplicate următoarele etape de preprocesare:

- Eliminarea coloanelor redundante și a acelor care conțineau un număr semnificativ de valori lipsă;
- Eliminarea valorilor lipsă din înregistrările rămase;
- Resetarea indexului pentru consistență;
- Conversia variabilelor categorice în format numeric (prin encoding);
- Salvarea datelor curățate într-un nou fișier CSV.

Aceste etape au fost esențiale pentru a reduce zgomotul din date și a asigura compatibilitatea cu modelele de învățare automată.

4.2 Modelarea datelor

După preprocesare, au fost definite seturile de date de antrenare și testare prin împărțirea datelor într-un raport de 80% – 20%.

Au fost antrenate și comparate următoarele modele:

- **Logistic Regression**, ca model de bază;
- **Random Forest**, cu un număr configurabil de arbori de decizie;

- **XGBoost**, cu parametrii optimizați pentru clasificare.

Modelul Random Forest a fost selectat ca fiind cel mai performant, pe baza scorului **F1**, care reflectă un echilibru între *precizie* și *recall* – metrică esențială în prezența unei distribuții dezechilibrate a claselor.

5 Testare si validare

6 Rezultate

6.1 Rezultate obținute

6.2 Compararea cu soluții existente

7 Concluzii și perspective de viitor

7.1 Concluzii

7.2 Perspective de viitor

References